

AI 연구 에이전트를 통한 문화적 역량(Culture-in-Action)의 수치화

저자: 정호영

초록 (Abstract)

사회학자 Ann Swidler(Swidler, 1986)은 'Culture-in-Action' 이론을 통해, '문화는 도구함(toolkit)이며 개인은 그로부터 역량을 길러 전략적 행위(strategies of action)를 구성한다는 틀'이라는 점을 확립했다. 이후 Wong-Villacres et al(2020)은 이를 기초 이론으로 두어, 라틴계 이민자 부모 35명의 참여디자인(PD) 자료에서 역량·목표·구조적 제약의 관계를 질적으로 해부했다. 그러나 이 해부의 타당성이 오직 훈련된 연구자의 질적 해석 능력에만 근거한다는 점(앵커 논문 자신의 논리 사슬에서 가장 취약한 전제, 3.1절 참조)에서 한계점을 가지고 있었다.

본 연구는 이 한계에서 출발해, 검색(Search)-근거추출(Grounding)-검증(Verification) 절차를 갖춘 AI 연구 에이전트가 이 질적 구성(도구함·역량·전략)을 원문에 근거를 둔 수치로, 즉 사례 간 비교와 개입 전후 효과 추적이 가능한 변수(**쉽게 말해 질적 변수를 양적 변수로 전환하는 과정**)로 변환할 수 있는지를 묻는다. 앵커 논문(**여기서 앵커 논문은 Wong-Villacres et al(2020)의 논문**)의 FOL 사슬에서 이 취약한 전제 하나를 교체하는 절차와, 도메인 일반적으로 세워졌던 최초의 열 개 하위 가설을 앵커 논문의 실제 사례에 맞추어 재 정식화하는 절차가 서로 독립적으로 동일한 지점(결측 판별의 이분법적 한계)에서 만난다는 사실을 확인했다. 이 결측 판별 항목은 "정보의 있음/없음"이라는 이분법이 과소추출(false negative) 오류를 놓친다는 사실을 드러내며 3단계 신뢰도 분류로 개정되었다. 재 정식화된 프레임워크를 앵커 논문이 실제로 보고한 두 전략 사례(Consejos, Closeness with teachers)에 원문 인용을 근거로 적용한 결과, 열 개 항목 모두 역추적 가능한 수치로 산출될 수 있음을 예시적으로 확인했다. 본 연구는 근거 없는 수치 생성(과잉추출)뿐 아니라 추론 가능한 정보의 누락(과소추출)까지 동시에 낮추는 것이 AI 기반 질적 수치화의 진짜 성공 기준이라는 새로운 가설을 제안하며, 그 완전한 실험적 검증은 향후 과제로 남긴다.

키워드: 문화적 도구함(Cultural Toolkit), 역량(Capacity), 전략적 행위(Strategies of Action), AI 연구 에이전트, 검색-근거추출-검증(S·G·V), 정량적 환각(Quantitative Hallucination)

0. 용어 설명

이 논문을 처음 읽는 독자를 위해, 본문에서 자주 등장하는 용어를 미리 쉬운 말로 풀

어둔다.

(1) **FOL (First-Order Logic, 1차 논리)**: "모든 사람은 죽는다 → 나는 사람이다 → 그러므로 나는 죽는다"처럼, 애매한 표현 없이 참(True)/거짓(False)을 명확히 가릴 수 있는 연역적 문장. 감상이나 추측이 아니라 근거를 따라가면 맞는지 틀린지 확인할 수 있어야 함.

(2) **도구함(toolkit) / 역량(capacity) / 전략적 행위(strategies of action)**: Swidler 이론의 세 층위.

- 도구함 = 문화가 제공하는 상징·이야기·관습의 연장 통.

- 역량 = 그 도구함(연장 통)에서 실제로 꺼내 쓸 줄 아는 기술.

- 전략적 행위 = 그 기술들을 엮어 만든 반복적인 문제해결 습관.

(3) **Settled(안정) / Unsettled(격변) 국면**: 안정기에는 이미 몸에 밴 습관대로 행동하고, 격변기에는 기존 습관이 안 통해 새로운 방법을 찾아 나선다는 구분.

(4) **검색(Search)·근거추출(Grounding)·검증(Verification), 줄여서 S·G·V**: AI 에이전트가 순서대로 해야 할 세 가지 일.

- 검색 = 원문에서 관련 부분 찾기.

- 근거추출 = 찾은 부분을 그대로 인용하며 숫자로 바꾸기.

- 검증 = 그 숫자가 인용한 부분과 실제로 맞는지 다시 확인하기.

(5) **과잉추출(false positive, FP) / 과소추출(false negative, FN)**:

- 과잉추출 = 원문에 없는 것을 있다고 지어내는 오류.

- 과소추출 = 원문에 있는 것을 없다고 놓치는 오류.(좋은 AI 에이전트는 이 둘 다 적어야 한다.)

(6) **주사슬 / 보조사슬**:

- 주사슬 = 가설을 직접 검증하는 핵심 항목들

- 보조사슬 = 그 검증의 전제조건이거나 결과를 종합하는 항목들.

(7) **공기(co-occurrence)**: 두 표현이 같은 문장이나 바로 옆 문장에 함께 나타나는 것.

(8) **균등가정**: 원문에 정확한 비중이 안 나와 있을 때, 항목 수만큼 똑같이 나눈다고 미리 밝혀두는 것. 진짜 비중이 아니라 "모르니 일단 똑같이 나눴다"는 임시방편임을 숨기지 않는 것이 핵심이다.

(9) **RAG(검색결합생성) / ReAct:**

- RAG = 언어모델이 답을 만들기 전에 외부 문서를 검색해 그 내용을 근거로 쓰는 방식.
- ReAct = 언어모델이 "생각하기"와 "검색 도구 실행하기"를 번갈아 하며 스스로 확인해가며 답을 찾는 방식.

(10) **정량적 환각(Quantitative Hallucination):** 언어모델이 근거 없는 숫자를 마치 사실인 것처럼 만들어내는 현상.

1. 서론

1.1 연구 배경

Human-Computer Interaction(HCI) 분야는 기술 기반 개입이 프로젝트 종료 이후에도 지속적으로 채택되도록 하는 문제를 오랫동안 다루어 왔는데, 이는 이미 존재하는 역량으로부터 설계가 시작되어야 한다고 본다(Kretzmann & McKnight, 1996; Moll, Amanti, Neff, & Gonzalez, 1992). 그러나 역량은 상황에 따라 자산도 되고 제약도 되는 유동적 성격을 가지므로, "어떤 역량을 어떤 설계 목적에 쓸 것인가?"라는 질문은 여전히 미해결로 남아 있었다(Cho, Herrera, Chaidez, & Uriostegui, 2019).

Wong-Villacres, DiSalvo, Kumar, & DiSalvo(2020)는 이 질문에 답하기 위해 문화사회학자 Ann Swidler의 이론을 분석의 기준 관점으로 도입했다. Swidler는 문화를 상징·이야기·의례로 이루어진 도구함(toolkit)으로 보고, 개인은 이로부터 역량(capacity)을 길러 지속적인 전략적 행위(strategies of action)를 구성한다고 주장한다. 이 관점은 Bourdieu(1977)의 자본 이론이 지닌 구조결정론적 한계와, Suchman(1987)의 상황적 행위 이론이 지닌 지나치게 미세한 분석 단위 문제 사이에서 중간 지점을 취한다. Wong-Villacres 등(2020)은 이 렌즈를 저소득 라틴계 이민자 부모 35명과 1개월 참여디자인(PD) 작업에 적용해, "Consejos(훈육적 조언)"와 "Closeness with teachers(교사와의 친밀성 추구)"라는 두 전략을 역량·목표·구조적 제약의 관계로 해부했다.

1.2 연구의 출발점과 기여

이 해부는 풍부한 질적 통찰을 제공하지만, 서술적(descriptive) 형태에 머문다. 앵커 논문 스스로도 이 해석의 타당성을 뒷받침하는 별도의 검증 절차를 제시하지 않으며, 그 근거는 훈련된 연구자의 질적 해석 능력에 의존하고 있다(3.1절에서 이 점을 앵커 논문 자체의 FOL 사슬로 직접 보인다). 서로 다른 참여자·전략 간 비교, 혹은 특정 기술 개입 전후의 효과 변화 역시 연구자의 정성적 판단에 의존할 수밖에 없다. 이 한계를 어떻게 넘어설 것인가라는 문제의식에서 본 연구가 출발했으며, 그 구체적인 경로는 3장에서 다

룬다.

본 연구는 다음을 기여한다. 첫째, 앵커 논문 자신의 논리 사슬 안에서 가장 취약한 전제를 식별하고, 그 전제 하나만을 새로운 주장으로 교체하는 절차를 통해 연구 문제를 도출한다. 둘째, Swidler의 Culture-in-Action 개념(도구함·역량·전략·settled/unsettled 국면)을 조작적으로 정의된 열 개의 하위 명제(FOL)로 분해하는 프레임워크를 제안한다. 셋째, 이 중 가장 취약한 고리인 결측 판별 항목을 반증 논리로 검토하여, 이분법적 판별이 과소추출 오류를 은폐한다는 방법론적 결함을 드러내고 3단계 신뢰도 분류로 개정한다. 넷째, 개정된 프레임워크를 앵커 논문이 실제로 보고한 원문 인용에 적용해 실행 가능성을 예시적으로 입증하고, 완전한 실험적 검증이 요구하는 조건을 명시한다.

2. 관련 연구

2.1 실천이론과 문화사회학

Bourdieu(1977)는 사회가 가치 있다고 여기는 자본(capital)의 축적 메커니즘이 이미 자본을 가진 집단에 유리하게 작동한다고 보았다. 이 관점은 구조적 제약을 설명하는 데는 강력하지만, 소외된 집단이 권력에 저항하기 위해 동원하는 역량을 설명하는 데는 지나치게 결정론적이다. Suchman(1987)의 상황적 행위(situated action) 이론은 특정한 장(setting)에서 행위하는 사람들의 일상 활동에 초점을 맞추어 개인의 행위성(agency)을 복원하지만, 분석 단위가 지나치게 미세해 장기간에 걸친 자료 분석에는 적합하지 않다. Swidler(1986)의 culture-in-action 이론은 이 두 접근 사이에서 중간 지점을 취한다. 구조적 제약을 부정하지 않으면서도, 개인이 문화적 도구함에서 창의적으로 역량을 구성해 전략적 행위를 조립하는 과정을 함께 조명하기 때문이다.

2.2 자산기반 HCI 디자인

Kretzmann & McKnight(1996)과 Moll 등(1992)은 역량을 기반으로 설계가 시작되어야 한다는 원칙을 확립했다. Cho 등(2019)은 이 원칙을 HCI에 적용해, 히스패닉 가정이 정보 확산에 활용하는 comadrazgo(여성 간 긴밀한 우정)를 자산으로 식별하고 이를 활용하는 SMS 시스템을 설계했다. Wong-Villacres 등(2020)은 이 계보 위에서, 역량을 어떻게 식별할 것인가를 넘어 특정한 맥락(개별적인 환경)속에 있는 역량을 설계에 어떻게 연결할 것인가라는 방법론적 공백을 Culture-in-Action 관점으로 제시한다.

2.3 AI 연구 에이전트와 정량적 환각

Lewis 등(2020)이 제안한 검색결합생성(Retrieval-Augmented Generation, RAG)은 파라메트릭 언어모델(치수만 바꾸면 형태가 자동으로 바뀌는 언어모델)과 비(非)파라메트릭 검색 정보를 결합해, 생성된 내용의 출처(provenance)를 제공할 가능성을 열었다. Yao 등(2023)의 ReAct는 언어모델의 추론(reasoning)과 행동(acting, 예: 검색 도구 호출)을 교차

시커, 사고 사슬(chain-of-thought)만으로 발생하는 환각과 오류 전파를 줄이는 방법을 제시했다. 그러나 Ji 등(2023)이 정리하듯, 언어모델이 생성하는 텍스트에는 근거 없는 내용을 사실처럼 제시하는 환각이 구조적으로 내재한다. 이 세 흐름은 AI가 정보를 찾고 근거를 추출하고 검증할 수 있다는 기술적 가능성과, 근거 없는 값을 지어낼 수 있다는 위험을 동시에 시사한다.

3. 연구의 출발점: 앵커 논문의 취약 고리와 최초 가설의 재 정식화

3.1 앵커 논문 자신의 FOL 사슬과 취약 고리

본 연구는 먼저 앵커 논문 자체가 주장하는 바를 1차 논리(FOL, 여기서 FOL이란 1차 논리(First-Order Logic)의 약자로, 삼단논법처럼 참(True)/거짓(False)을 엄밀하게 판별할 수 있는 연역적 인과관계 문장을 의미) 사슬로 추출했다. 앵커 논문의 핵심 논제(FOL 0)는 다음과 같다. Swidler의 culture-in-action 이론(문화는 연장 통(도구함)이고, 사람은 그 연장 통에서 기술(역량)을 배워 그 기술들을 엮어 반복적인 문제해결 습관(전략적 행위)을 만든다는 틀을 설명, 자세한 정의는 4장에서 다룸)은 "situated(쉽게 말해 상황에 따라 달라지는)한 역량 중 무엇을 어떤 설계 목적에 활용해야 하는가"라는 문제를 분석하는데 유효한 관점이라는 것이다. 이를 지지하는 아홉 개의 하위 명제(FOL 0-1~9)는 다음과 같다.

- (1) FOL 0-1: 자산기반 설계는 결핍이 아닌 이미 존재하는 자산·역량에서 개입을 시작해야 한다. (구체적으로 말하면, 사람들에게 "무엇이 부족한가"를 먼저 묻지 않고 "이미 무엇을 잘하고 있는가"부터 본다는 원칙)
- (2) FOL 0-2: 역량은 상황에 따라 자산도 되고 제약도 되는 situated한 성격을 가지므로, 어떤 역량을 어떤 설계 목적에 쓸 것인가는 여전히 미해결 질문이다. (구체적으로 말하면, 예를 들어 "인내심"은 어떤 상황에서는 큰 도움이 되지만, 다른 상황에서는 오히려 새로운 방법을 못 찾게 막는 걸림돌이 될 수도 있으므로 이 역량을 언제 활용해야 좋은지 미리 정해두기 어렵다는 뜻을 의미)
- (3) FOL 0-3: Activity Theory(활동이론), Bourdieu(부르디외)의 자본이론, Suchman(서치먼)의 situated action(상황적 행위) 이론은 각각 한계가 있다. (구체적으로 말하면, 활동이론은 불평등 문제를 지나치게 낙관적으로만 보고, 부르디외 이론은 "가난은 대물림된다"는 식으로 지나치게 결정론적이며, 서치먼의 이론은 지나치게 미시적이라 짧은 순간의 행동만 설명할 뿐 오랜 기간에 걸친 자료에는 맞지 않는다)
- (4) FOL 0-4: Swidler의 culture-in-action은 구조적 제약을 인정하면서도 개인의 창의적 행위성을 함께 조명하는 중간 지점을 제공한다. (구체적으로 말하면: 위 세 이론의 극단을 피해, "사회적 제약은 분명히 있지만 그 안에서도 사람은 창의적으

로 대응한다"는 절충안)

- (5) **FOL 0-5:** 문화는 상징·이야기·의례로 이루어진 도구함이며, 개인은 이로부터 역량(습관·기술·스타일)을 길러 지속적인 전략적 행위를 구성한다. (구체적으로 말하면: 도구함 = 문화가 제공하는 연장통, 역량 = 그 연장통에서 실제로 쓸 줄 아는 기술, 전략 = 그 기술들을 조합해 만든 습관적인 문제해결 방식)
- (6) **FOL 0-6:** 전략적 행위라는 분석 단위로 접근하면, 어떤 역량이 어떤 목표를 지지하며 어떤 구조적 제약에 부딪히는지 심층적으로 드러난다. (구체적으로 말하면: "이 사람이 왜 이렇게 행동하는가"를 알고 싶으면, 그 사람의 반복되는 행동 패턴 하나를 통째로 뜯어보면 역량·목표·제약의 관계가 한 번에 드러나는 것)
- (7) **FOL 0-7:** Settled(안정) 국면에서는 이미 갖춘 역량과 전략의 가용성이 목표 선택을 결정하고, unsettled(격변) 국면에서는 개인이 도구함을 재검토하며 전략을 재구성한다. (구체적으로 말하면: 평소에는 몸에 밴 습관대로 행동하지만, 위기가 닥치면 사람들은 자기가 가진 문화적 자원을 다시 뒤져 새로운 방법을 시도)
- (8) **FOL 0-8:** 이 렌즈를 라틴계 이민자 부모 35명과 1개월 참여디자인(PD) 자료에 적용하면, "Consejos"와 "Closeness with teachers"라는 두 전략에서 역량·목표·제약의 관계가 실제로 드러난다. (구체적으로 말하면: 실제로 인터뷰해봤더니 "자녀에게 조언 주기"와 "교사와 친해지기"라는 두 가지 뚜렷한 습관적 행동 패턴이 나타나는 것)
- (9) **FOL 0-9:** 이러한 심층 해부는 설계자가 어떤 역량을 어떤 목적으로 활용할 지에 대한 새로운 설계 방향을 도출하게 한다. (구체적으로 말하면: 이렇게 뜯어본 결과를 바탕으로, 실제로 어떤 기술을 만들면 좋을지 구체적인 아이디어가 나오는 것)

마지막 열 번째 명제는 다음과 같다.

(10) **FOL 0-10:** 따라서 culture-in-action 관점은 situated capacity 문제에 대한 방법론적 해법을 제공하며, 이 해석의 타당성은 훈련된 연구자(저자들)의 질적 해석 능력에 근거하지만, 논문 전체에 걸쳐 이 해석을 독립적으로 재현하거나 수치로 교차 검증하는 절차는 제시되지 않는다. (구체적으로 말하면: "그래서 이 이론적 관점은 쓸모가 있다"라는 해석이 맞는지는 오직 이 논문을 쓴 연구자의 판단력에 의존한다는 뜻)

FOL 0-1~0-9는 각각 선행 연구 인용이나 원문의 실제 사례로 뒷받침되지만, FOL 0-10의 마지막 절은 논문 스스로도 명시적으로 검증하지 않는 암묵적 전제다. 이 전제가 가장 취약한 고리다: 해석이 유일하게 연구자 개인의 질적 판단에만 의존한다면, 서로 다른 사례·연구자 간 비교나 재현은 원칙적으로 불가능하다. 본 연구는 바로 이 하나의 고리만

을 다음 주장으로 교체한다.

situated capacities의 해석은 훈련된 연구자의 질적 해석에만 의존하지 않아도 된다. 검색·근거추출·검증(S·G·V, 자세한 설명은 5.1절에 있다) 절차를 가진 AI 연구 에이전트가 원문에 역추적 가능한 수치를 산출함으로써, 해석의 타당성을 인간 연구자 단독의 판단을 넘어 검증 가능한 형태로 보완할 수 있다.

3.2 독립적으로 세운 최초 가설과의 수렴

이 절차와는 별개로, 본 연구는 초기에 일반적인 형태의 가설도 세웠다. 즉 AI 에이전트는 개인의 문화적 도구함·역량·전략처럼 본래 수치화하기 어려운 질적 현상을 원문의 의미를 왜곡하지 않으면서 수치적 값으로 변환할 수 있다는 것이다. 이 주장을 지탱하기 위해 처음 도출된 열 개의 하위 명제(FOL 0-1~0-10)는, 도구 함 요소의 다양성 환산 가능성부터 개입 전후 변화 추적 가능성까지 각각 서로 다른 질문을 던졌으며, 그 중 "역량 부재를 정직하게 N/A로 처리하는가"를 묻는 FOL 0-6이 가장 중요한 항목으로 지목되었다.

이 최초의 FOL 0에는 두 가지 한계가 있었다. 첫째, 각 명제가 예시로 든 사례가 실제로 존재하는 단일 원문을 지시하지 않아 "역추적 가능한 근거"라는 기준 자체를 검증할 방법이 없었다. 둘째, 이론적 배경이 명시되지 않아 도구 함·역량·전략이라는 용어가 어떤 학술적 개념에 대응하는지 불분명했다. 흥미로운 점은, 앵커 논문을 확보한 뒤 3.1절의 정식 절차(앵커의 FOL 사슬 추출 → 취약 고리 식별)를 별도로 수행한 결과 도달한 지점 이, 이 최초 탐색이 독립적으로 지목한 FOL 0-6과 정확히 같은 문제(질적 해석·결측 판별의 타당성을 어떻게 확인할 것인가)였다는 사실이다. 서로 다른 두 경로가 같은 취약점으로 수렴한다는 것은 이 취약점이 우연이 아님을 시사한다. 이하 4장과 5장은 열 가지 명제 각각이 앵커 논문 위에서 어떻게 재정식화 되었는지를 서술한다.

4. 이론적 틀: Culture-in-Action의 재구성

Swidler(1986)의 이론은 세 가지 구성요소로 이루어진다. 도구함(toolkit)은 상징·이야기·의례로 구성된 문화적 자원의 총체이며, 역량(capacity)은 그 도구함으로부터 길러지는 습관·기술·스타일이고, 전략적 행위(strategies of action)는 역량을 동원해 조립한, 목표를 지속적으로 추구하는 방식이다. 이 이론은 또한 안정(settled)과 격변(unsettled) 국면을 구분한다. 안정된 국면에서는 이미 갖춘 역량과 전략의 가용성이 목표 선택 자체를 결정하는 반면, 격변의 국면에서는 개인이 자신의 도구함을 의식적으로 재검토하며 전략을 재구성한다. Wong-Villacres 등(2020)은 이 구분을 실제 자료 분석에 그대로 적용하여, 부모들이 심각한 학업 문제에 직면했을 때 겪는 상태를 "unsettled times(격변하는 상황)"라고 명명하며 서술했는데, 이는 6장에서 볼 것처럼 이론적 구성개념이 실제 서술 안에 찾아낼 수 있는 형태로 존재한다는 것을 보여주는 첫 단서가 된다.

5. 방법론: 재 정식화된 기반

5.1 AI 에이전트가 갖추어야 할 세 기능

본 기반이 요구하는 에이전트는 세 기능을 순서대로 수행해야 한다. 원문에서 관련 대목을 정확히 찾아내는 검색(Search, 이 주장을 뒷받침할 문장이 원문 어디에 있는가를 찾는 단계), 찾아낸 대목을 근거 문장으로 인용하며 값을 산출하는 근거추출(Grounding, 찾은 문장을 그대로 인용하면서 숫자로 바꾸는 단계), 그리고 산출된 값이 실제로 근거 문장과 일치하는지 재확인하는 검증(Verification, 숫자와 인용문을 다시 대조해 틀리지 않았는지 확인하는 단계)으로 구성된다. (줄여서 S·G·V라고 부름)

5.2 열 개의 하위 명제 재 정식화: 주사슬과 보조사슬

3.2절에서 소개한 열 개의 하위 FOL 명제는 다음과 같이 구체화되었다.

- (1) FOL 0-1(도구함 다양성)은 도구함 요소를 개체로 식별·목록화하고, 고유 요소 수를 언급 참여자 수로 나눈 다양성 지수를 산출하는 것으로 정식화되었다. 예) 한 참여자가 "전화로 연락했다", "이웃에게 부탁했다", "가족에게 대신 시켰다"는 세 가지 서로 다른 방법을 언급했다면, 고유 요소 수는 3, 참여자 수는 1이므로 다양성 지수 $= 3/1 = 3.0$ 이다.
- (2) FOL 0-2(연결강도)는 문장 간 거리와 인과 연결어의 존재를 반영해 $1/(\text{문장거리}+1)$ 이라는 근접도 산식으로 다듬어졌다. 여기서 "문장 간 거리"란 역량이 언급된 문장과 그 근거(도구함 요소)가 언급된 문장이 서로 몇 문장 떨어져 있는지를 뜻한다. 예) "나는 인내심이 강해서 포기하지 않았다"처럼 역량과 근거가 같은 문장에 붙어 있으면 문장거리 = 0, 연결강도 $= 1/(0+1) = 1.0$. 두 문장 떨어져 있으면 연결강도 $= 1/(2+1) \approx 0.33$ 으로 낮아진다.
- (3) FOL 0-3(안정 국면의 영향력)은 역량과 전략이 같은 문장에서 공기(co-occurrence, 두 표현이 같은 문장이나 바로 옆 문장에 함께 나타나는 것)하는 정도와 확인 표현(예를 들어 "항상", "대부분", "누구나"처럼 예외 없이 그렇다고 단정하는 말투)의 존재를 근거로 0에서 1 사이의 점수를 매기는 방식으로 재 정식화되었다.
- (4) FOL 0-4(격변 국면의 재검토 빈도)는 전략전환을 알리는 표현(예: "다시", "대신", "새로운 방법으로"처럼 기존 방식을 버리고 다른 방식을 시도한다는 신호어)의 등장 빈도를 해당 문단의 전체 문장 수로 나누는 방식으로 재 정식화되었다. 예) 열 두 문장 중 이런 신호어가 세 번 나오면 재검토 지수 $= 3/12 = 0.25$.
- (5) FOL 0-5(전략의 역량 기여도 분해)는 원문에 명시적 가중치가 없는 경우 균등 배분임을 밝히는 조건을 달아 유지되었다. 균등가정이란 원문에 정확한 비중이 안

나와 있을 때 항목 수만큼 똑같이 나눈다고 미리 밝혀두는 것이다. 예) 역량이 3개인데 어느 것이 더 중요한지 원문에 안 나와 있으면, 그냥 각각 $100\%/3 \approx 33.3\%$ 씩 배분하되 "이것은 실제 비중이 아니라 균등 가정"이라고 반드시 표시한다.

- (6) FOL 0-7(구조적 제약의 가용률)은 원문에 실제로 명시된 수치만을 사용해야 한다는 제약이 추가되었다. 예) "하루 20명이 상담을 원하는데 교사는 시간이 없다"는 문장이 있으면, 실제 상담 가능 인원(원문에 나온 사례 수) ÷ 대기 인원(20명)으로 가용률을 계산한다. 원문에 숫자가 없으면 억지로 계산하지 않고 결측(N/A)으로 남긴다.
- (7) FOL 0-8(역량의 양가성)은 긍정 문맥 수에서 부정 문맥 수를 뺀 값을 전체 문맥 수로 나누는 부호 점수로 정식화되었다. 예) 같은 역량을 두고 "도움이 되었다"는 문장과 "오히려 방해가 되었다"는 문장이 하나씩 같이 나오면, $(1-1)/2 = 0$ 으로, 자산과 제약이 팽팽하게 맞선 상태임을 숫자로 보여준다.
- (8) FOL 0-9(다중요인 종합 부합도)와 FOL 0-10(개입 전후 변화 추적)은 각각 가중치 가정을 투명하게 명시하는 것과, 개입 전후 문단에 동일한 산식을 일관되게 적용하는 것을 조건으로 유지되었다. 예) 역량 3개, 제약 2개가 있고 제약에는 역량의 절반 정도 무게만 준다고 가정하면(이 가정 자체를 반드시 밝혀야 한다), 부합도 $= (3-2 \times 0.5) / 5 = 0.4$ 가 된다. 기술 도입 전후로 이 계산을 각각 반복해 그 차이(Δ , 델타)를 보면 개선 여부를 알 수 있다.

이 아홉 개 명제 가운데 FOL 0-2·FOL 0-4·FOL 0-7·FOL 0-8은 5.1절의 세 기능(S·G·V)을 직접 활용해 정확도와 환각 감소라는 목표를 곧바로 검증하는 주사술을 이루고, FOL 0-1·FOL 0-3·FOL 0-5·FOL 0-9·FOL 0-10은 그 전제조건이 되거나 결과를 종합하는 보조사술을 이룬다.

5.3 FOL 0-6의 재검토: 이분법에서 3단계 분류로

가장 중요한 항목으로 지목되었던 FOL 0-6(결측 판별)은 단순한 재 정식화를 넘어 근본적인 재검토를 거쳤다. 이 명제는 원래 "정보가 있다/없다"는 이분법을 전제로, AI가 정보 부재를 정직하게 N/A로 처리하는지를 물었다. 그러나 이 이분법은 실제 서술에서 명시적 진술과 완전한 부재 사이에 암묵적으로 추론 가능한 근거라는 중간 지대가 존재한다는 사실을 놓친다.

여기서 두 가지 오류를 구분할 필요가 있다. 과잉추출(false positive, FP)이란 실제로는 원문에 없는 정보를 AI가 마치 있는 것처럼 지어내는 오류다(예: 없는 숫자를 만들어내는 것). 과소추출(false negative, FN)이란 반대로 원문에 충분히 암시되어 있는 정보인데도 AI가 지레 "모른다(N/A)"고 답해버리는 오류다. 검증 절차가 과잉추출만을 억제하도록 설

계되면, 에이전트는 그 대가로 과소추출에 빠질 수 있다. 이 경우 환각이 없다는 지표만으로는 아무 답도 하지 않는 에이전트가 최고 점수를 받는 자기모순이 발생한다. 이에 이 명제는, AI 에이전트가 정보의 존재 여부를 이분법이 아니라 명시적 근거·암묵적 근거(신뢰도 점수 부여)·부재라는 3단계로 판별해야 하며, 성공 기준 또한 과잉추출뿐 아니라 과소추출까지 함께 낮추는 것이어야 한다는 형태로 개정되었다(FOL 0-6').

5.4 최초 가설의 재 정식화

이러한 재검토를 반영해, 최초의 검증 가설 또한 다듬어졌다. 재 정식화된 가설(FOL 1')은, 검색·근거추출·검증 절차를 갖춘 AI 연구 에이전트가 단순 언어모델 요약 대비 근거 없는 수치 생성을 줄이는 동시에 원문에 암묵적으로 내포된 정보를 놓치지 않고 포착해 두 오류를 동시에 낮추는 방향으로 원문-부합 정확도를 개선하리라는 것이다. 다만 환각 감소가 단순히 응답 회피, 곧 N/A의 남발로 달성된 것이라면 이는 이 가설의 반증 사례로 간주되어야 한다는 단서가 함께 명시되었다.

6. 사례 적용: 앵커 논문 데이터 재분석

본 절은 5장에서 재 정식화된 프레임워크를 앵커 논문이 실제로 보고한 원문 인용에 근거 추적이 가능한 형태로 적용한다. 모든 수치는 수기 산출(manual computation)이며, 계산에 사용한 가중치가 원문에 명시되지 않은 경우 이를 매번 밝힌다. 인용된 참여자 가명은 앵커 논문 원문을 그대로 따른다.

6.1 "Consejos" 전략 분석

도구함 다양성을 묻는 FOL 0-1을 적용하면, 부모들이 동원한 도구함 요소는 다음 네 가지로 식별된다.

- (1) 가족 출신과 계급에 관한 서사 = "I tried to make them see where they come from..." (Clara)
- (2) superación(자기 성취) 담론 = "he needs to have a clearly defined goal..." (Regina)
- (3) 개인적 실패-극복 서사 = "the best students... calling me a 'burro'..." (Roberto)
- (4) 인내에 관한 신념 = "my strength is to be perseverant..." (Regina)

이 네 요소를 언급한 참여자는 Clara, Regina, Roberto 세 명이다(Regina가 2번과 4번, 두 요소를 함께 언급했으므로 요소 수가 참여자 수보다 많아진다). 다양성 지수는 "고유 요소 수 ÷ 언급 참여자 수"로 정의했으므로 $4 \div 3 = 1.333\dots$, 소수점 둘째 자리에서 반올림해 1.33으로 표기한다.

연결강도를 묻는 FOL 0-2를 적용하면, Roberto의 역량("academic resources can be

mixed with values-based ones")과 그 근거가 되는 그의 개인 서사("the best students... calling me a 'burro'...")는 같은 문단, 서로 인접한 문장에서 등장한다. 문장거리를 "두 표현 사이에 몇 개의 다른 문장이 끼어 있는가"로 정의했으므로, 이 경우 사이에 낀 문장이 0개이니 문장거리 = 0이다. 근접도 산식 $1/(\text{문장거리}+1)$ 에 대입하면 $1/(0+1) = 1.0$ 이 된다.

안정 국면의 영향력을 묻는 FOL 0-3은 다음 채점 규칙을 따른다. 원문에 "all", "every"처럼 예외 없는 표현이 쓰이고 역량과 전략이 같은 문장에 있으면 1.0, "most", "almost all"처럼 대다수를 뜻하는 표현이면 0.9, "some", "a few"처럼 부분적 표현이면 0.5 이하로 낮춘다. 원문 "As most of our participants, Regina only used values-based resources... to craft consejos for motivating academic development"는 "most"라는 표현을 쓰면서 역량(values-based resources)과 전략(consejos)이 한 문장에 함께 있으므로, 이 규칙에 따라 0.9로 산정한다.

6.2 "Closeness with teachers" 전략 분석

격변 국면의 재검토 빈도를 묻는 FOL 0-4는 다음 문단에 적용한다. (앵커 논문의 원문 그대로 인용)

"Lucia's experience illustrates our analysis. Like Lucia, many immigrant parents have developed distrust-based strategies for protecting their family and themselves. 'I don't like to confide my problems to anybody else than my husband, my children, and God,' she told us. This, however, tends to keep her isolated from diverse information that could help her family. When her nine y/o son started to show discipline and academic problems, she faced an unsettled time: 'Looking back, those were hard days. I had no idea what to do, and prayed to God for an answer.' In line with a culture-in-action's description of people's conscious, exploratory behavior during unsettled times, Lucia looked into her cultural toolkit and found a strategy she felt could work: attempting to negotiate information on a one-on-one interaction, in this case, with the teacher. This is a strategy we saw most of our participants leveraging for most of their information-seeking problems, from finding a new apartment, to finding solutions for medical problems."

이 문단을 마침표 기준으로 나누면(따옴표 안의 문장도 각각 별도로 센다) 총 8개의 문장이 된다: ①Lucia's experience illustrates our analysis. ②Like Lucia, many immigrant parents... ③"I don't like to confide..." ④This, however, tends to keep her isolated... ⑤she faced an unsettled time: "Looking back, those were hard days." ⑥"I had no idea what to do, and prayed to God for an answer." ⑦In line with... Lucia looked into her cultural

toolkit and found a strategy she felt could work: attempting to negotiate information...

⑧ This is a strategy we saw most of our participants leveraging...

이 중 전략전환을 알리는 표현이 담긴 문장은 ⑤번("she faced an unsettled time")과 ⑦번("looked into her cultural toolkit and found a strategy she felt could work") 두 개다. 따라서 재검토 지수 = 마커가 담긴 문장 수 ÷ 전체 문장 수 = $2/8 = 0.25$ 가 된다. 전략의 역량 기여도 분해를 묻는 FOL 0-5는, Closeness 전략을 다음 세 개 역량으로 분해한다: 인내와 용기("courageously, despite the fear of humiliation"), 권위자에 대한 신뢰 추구("secure a connection with a trusting figure of authority"), 협상 능력("negotiating information"). 원문에 이 세 역량 각각의 상대적 비중은 나와 있지 않으므로, 항목 수 3으로 100%를 나누어 각각 $100/3 \approx 33.3\%$ 씩 균등 배분한다고 명시한다. 결측 판별을 묻는 FOL 0-6'은 여기서 3단계 분류의 실제 효과를 보여준다.

- (1) **명시적 근거(100%)**: "all our participants, at a certain point, had tried to get closer to teachers"는 "all"이라는 표현이 그대로 쓰였으므로 100%로 판정한다.
- (2) **결측(N/A)**: 개별 참여자가 평균 몇 번 교사에게 접촉했는지를 나타내는 수치는 원문 어디에도 없으므로, 추정하지 않고 N/A로 남긴다.
- (3) **암묵적 근거(신뢰도 0.6)**: Melina가 다른 학습자원을 거부한 대목("I first have to do what the teacher told me to do")은 태도가 구체적인 발화로 명확히 서술되어 있으므로 완전한 결측(0)은 아니지만, 그 강도를 나타내는 수식어("항상", "매번" 등)가 없어 완전한 확신(1.0)도 줄 수 없다. 구체적 발화 근거는 있으나 강도 수식어가 없는 이런 경우를, 발화 근거가 전혀 없는 경우(0.3~0.4 구간)보다는 높고 강도 수식어까지 갖춘 경우(0.8~1.0 구간)보다는 낮은 중간값으로 잡아 0.6으로 산정한다.

바로 이 세 번째 판정이 5.3절에서 개정한 3단계 분류가 실제로 작동하는 지점이다. 구조적 제약의 가용률을 묻는 FOL 0-7은 원문에 실제로 명시된 두 수치를 그대로 사용한다. Esther의 발언 "teachers do not have the time to meet with 20 parents wanting to talk to them per day"에서 하루 대기 수요는 20명이다. 원문이 실제로 성공 사례로 서술한 인원(개별 성공 사례로 언급된 Lucia, Melina 등)을 최소 1건으로 잡으면, 가용률 = $1 \div 20 = 5\%$ 가 된다. 이 '1건'은 원문이 개별 성공 사례만 서술할 뿐 전체 성공 인원 수를 명시하지 않기 때문에 잡은 최소 추정치이며, 실제 가용률은 이보다 높을 수 있음을 밝혀둔다.

역량의 양가성을 묻는 FOL 0-8은 "perseverance helped many parents pursue a form of support for children, but it also blinded them from other opportunities"라는 한 문장을 사용한다. "helped... pursue a form of support"는 긍정 문맥 1개, "blinded them from

other opportunities"는 부정 문맥 1개로 센다. 부호 점수 = (긍정 문맥 수 - 부정 문맥 수) ÷ 전체 문맥 수 = (1-1)/2 = 0이 되어, 완전히 균형 잡힌 양가성을 수치로 드러낸다.

6.3 종합 및 개입 전후 비교

다중요인 종합 부합도를 묻는 FOL 0-9는 원문이 직접 제시한 종합 사례를 사용한다: "parents' capacities to solve the problem of social discomfort are control of their own space, appreciation of superación... and the ability to find online resources... Their limitations... are embarrassment and social fear. Juxtaposing both reveals that their overall goal is safe self-empowerment." → 여기서 역량은 3개(자기 공간 통제, superación 추구, 온라인 자원 탐색 능력), 제약은 2개(embarrassment, social fear)다. 제약은 역량의 절반 정도 무게만 상쇄한다고 가정하면(원문에 없는 가정이므로 반드시 명시), 부합도 = (역량 수 - 제약 수×0.5) ÷ 전체 요소 수 = (3 - 2×0.5) ÷ 5 = (3-1)/5 = 0.4가 된다.

개입 전후 변화를 묻는 FOL 0-10은 같은 계산식을 Closeness 전략에 두 번 적용한다. 개입 전: 역량 2개(perseverance, trust-seeking), 제약 2개(교사의 시간 부족, 낮은 신뢰 평점) → $(2-2\times0.5)/4 = (2-1)/4 = 0.25$. 개입 후(원논문이 제안한 "intelligent agents embedded in existing parent-teacher communication channels"): 이 개입이 "교사의 시간 부족"이라는 제약을 상쇄한다고 보면 제약이 1개(낮은 신뢰 평점)만 남으므로 → $(2-1\times0.5)/3 = (2-0.5)/3 = 0.5$. 두 값의 차이, $\Delta = 0.5 - 0.25 = +0.25$ 로, 개입이 부합도를 개선하는 방향으로 작용함을 보여준다.

7. 논의

6장의 적용 결과는 주사슬을 이루는 네 개의 FOL(연결강도·재검토 빈도·결측 판별·가용률·양가성)이 모두 원문 근거로 역추적 가능한 수치를 산출할 수 있음을 보여준다. 특히 6.2절에서 확인했듯 앵커 논문 저자들이 Swidler의 unsettled 개념을 문자 그대로 차용해 서술했다는 사실은, 이론적으로 정의된 구성개념이 실제 질적 서술 안에 찾아낼 수 있는 형태로 이미 존재함을 시사한다. 이는 최초의 FOL 0이 주장했던 바(질적 현상이 원문의 의미를 왜곡하지 않고 수치로 옮겨질 수 있다는 것)를 지지하는 가장 직접적인 증거이자, 3.1절에서 앵커 논문 자체의 FOL 사슬을 교체해 도출한 것과 동일한 방향의 결론이다.

동시에 FOL 0-5·FOL 0-9·FOL 0-10에서 반복된 균등가정 표기는, 원문이 가중치나 빈도를 항상 명시하지는 않는다는 한계도 함께 보여준다. 즉 이 프레임워크의 신뢰도는 결국 원문에 없는 값에 대한 정직한 표기, 곧 재정식화된 FOL 0-6'에 좌우된다.

8. 한계 및 향후 연구

본 연구의 사례 적용은 한 명의 분석자가 수기로 원문을 대조하며 산출한 것이며, 검증 루프가 있는 에이전트와 없는 에이전트를 실제로 병렬 가동해 과잉 추출률과 과소 추

출률을 통계적으로 비교하는 실험은 수행되지 않았다. 따라서 재 정식화된 최종 가설이 주장하는 두 오류의 동시 저감은 방법론적 실행 가능성만 예시적으로 입증되었을 뿐, 완전히 검증되지는 않았다. 향후 연구는 검증 루프의 유무를 조작한 에이전트 간 비교 실험, 다수의 암묵적 근거 신뢰도의 평가자 간 신뢰도 측정, 그리고 언급된 Consejos와 Closeness 외 다른 전략 사례로의 일반화 가능성 검토를 과제로 삼는다.

9. 결론

본 연구는 두 개의 독립적인 경로(앵커 논문 자신의 FOL 사슬에서 가장 취약한 고리를 찾아 교체하는 정식 절차와, 일반적으로 세워졌던 최초 가설을 앵커 논문의 실제 사례에 맞추어 재 정식화하는 탐색적 절차)가 동일한 지점(질적 해석·결측 판별의 타당성 문제)으로 수렴함을 보였다. Swidler(1986)의 culture-in-action 이론과 이를 HCI에 적용한 Wong-Villacres 등(2020)의 논문 사이에서, 이것의 산출물이 AI 에이전트에 의해 원문-근거 기반으로 수치화될 수 있는가라는 연구 공백을 확인했고, 가장 취약했던 결측 판별 항목을 반증을 통해 3단계 신뢰도 분류로 개정했다. 앵커 논문의 실제 사례에 대한 예시적 적용은 이 프레임워크의 실행 가능성을 뒷받침하며, 과잉추출과 과소추출을 동시에 낮추는 것이 진짜 성공 기준이라는 재 정식화된 가설을 제시한다. 이 가설의 완전한 실험적 검증은 향후 과제로 남는다.

참고문헌

- Bourdieu, P. (1977). *Outline of a Theory of Practice*. Cambridge University Press.
- Cho, A., Herrera, R. G., Chaidez, L., & Uriostegui, A. (2019). The "Comadre" Project: An Asset-Based Design Approach to Connecting Low-Income Latinx Families to Out-of-School Learning Opportunities. In *Proceedings of the 2019 CHI Conference on Human Factors in Computing Systems*. ACM.
- Ji, Z., Lee, N., Frieske, R., Yu, T., Su, D., Xu, Y., ... & Fung, P. (2023). Survey of Hallucination in Natural Language Generation. *ACM Computing Surveys*, 55(12), Article 248. <https://doi.org/10.1145/3571730>
- Kretzmann, J., & McKnight, J. P. (1996). Assets-based community development. *National Civic Review*, 85(4), 23–29.
- Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., ... & Kiela, D. (2020). Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. In *Advances in Neural Information Processing Systems 33 (NeurIPS 2020)*. <https://arxiv.org/abs/2005.11401>

Moll, L. C., Amanti, C., Neff, D., & Gonzalez, N. (1992). Funds of knowledge for teaching: Using a qualitative approach to connect homes and classrooms. *Theory into Practice*, 31(2), 132–141.

Suchman, L. A. (1987). *Plans and Situated Actions: The Problem of Human-Machine Communication*. Cambridge University Press.

Swidler, A. (1986). Culture in action: Symbols and strategies. *American Sociological Review*, 51(2), 273–286. <https://doi.org/10.2307/2095521>

Wong-Villacres, M., DiSalvo, C., Kumar, N., & DiSalvo, B. (2020). Culture in Action: Unpacking Capacities to Inform Assets-Based Design. In *Proceedings of the 2020 CHI Conference on Human Factors in Computing Systems (CHI '20)*. <https://doi.org/10.1145/3313831.3376329>

Yao, S., Zhao, J., Yu, D., Du, N., Shafran, I., Narasimhan, K., & Cao, Y. (2023). ReAct: Synergizing Reasoning and Acting in Language Models. In *Proceedings of the 11th International Conference on Learning Representations (ICLR 2023)*. <https://arxiv.org/abs/2210.03629>