

검증 가능한 AI 연구 에이전트를 통한 문화적 역량의 수치화: Culture-in-Action 렌즈의 재구성

저자: 정호영

초록 (Abstract)

자산기반 설계(assets-based design)는 개인의 결핍이 아닌 역량(capacity)에서 설계를 시작해야 한다고 주장하지만, 상황에 따라 달라지는 역량의 situated한 성격 때문에 "어떤 역량을 어떤 목적에 활용할 것인가"라는 질문에는 답하기 어려웠다. Wong-Villacres 등(2020)은 이 문제에 사회학자 Ann Swidler의 culture-in-action 이론(문화는 도구함(toolkit)이며 개인은 그로부터 역량을 길러 전략적 행위(strategies of action)를 구성하는 틀)를 분석 렌즈로 도입해, 라틴계 이민자 부모 35명의 참여디자인(PD) 자료에서 역량·목표·구조적 제약의 관계를 질적으로 해부했다.

본 연구는 이 해부가 여전히 서술적 수준에 머물러 사례 간 비교나 개입 전후 효과의 정량적 추적이 불가능하다는 한계에서 출발해, 검색(Search)·근거추출(Grounding)·검증(Verification) 절차를 갖춘 AI 연구 에이전트가 이러한 질적 구성을 원문에 근거를 둔 수치(정확히 계량 가능한 변수로 전환 가능한지)로 변환할 수 있는지를 묻는다. 최초로 세워졌던 열 개의 하위 가설(FOL)은, 앵커 논문을 실제로 확보한 뒤 Swidler의 개념과 그 논문의 실제 사례에 맞추어 재정식화되었고, 그 과정에서 가장 취약했던 결측 판별 항목은 "정보의 있음/없음"이라는 이분법이 과소추출(false negative) 오류를 놓친다는 사실을 드러내며 3단계 신뢰도 분류로 개정되었다. 재정식화된 프레임워크를 앵커 논문이 실제로 보고한 두 전략 사례(Consejos, Closeness with teachers)에 원문 인용을 근거로 적용한 결과, 열 개 항목 모두 역추적 가능한 수치로 산출될 수 있음을 예시적으로 확인했다. 본 연구는 근거 없는 수치 생성(과잉추출)뿐 아니라 추론 가능한 정보의 누락(과소추출)까지 동시에 낮추는 것이 AI 기반 질적 수치화의 진짜 성공 기준이라는 새로운 가설을 제안하며, 그 완전한 실험적 검증은 향후 과제로 남긴다.

키워드: 문화적 도구함(Cultural Toolkit), 역량(Capacity), 전략적 행위(Strategies of Action), AI 연구 에이전트, 검색-근거추출-검증, 정량적 환각(Quantitative Hallucination), 자산기반 설계(assets-based design)

1. 서론

1.1 연구 배경

Human-Computer Interaction(HCI) 분야는 기술 기반 개입이 프로젝트 종료 이후에도 지속적으로 채택되도록 하는 문제에 오랫동안 천착해 왔다. 이에 대한 유력한 접근이 자산기반 설계(assets-based design)로, 결핍이 아닌 이미 존재하는 역량에서 설계를 시작해야 한다고 본다(Kretzmann & McKnight, 1996; Moll, Amanti, Neff, & Gonzalez, 1992). 그러나 역량이 상황에 따라 자산도 되고 제약도 되는 유동적 성격을 갖는다는 점에서, "어떤 역량을 어떤 설계 목적에 쓸 것인가"라는 질문은 여전히 미해결로 남아 있었다(Cho, Herrera, Chaidez, & Uriostegui, 2019).

Wong-Villacres, DiSalvo, Kumar, & DiSalvo(2020)는 이 질문에 답하기 위해 문화사회학자 Ann Swidler의 이론(Swidler, 1986)을 분석 렌즈로 도입했다. Swidler는 문화를 상징·이야기·의례로 이루어진 도구함(toolkit)으로 보고, 개인은 이로부터 역량(capacity)을 길러 지속적인 전략적 행위(strategies of action)를 구성한다고 주장한다. 이 관점은 Bourdieu(1977)의 자본 이론이 지닌 구조결정론적 한계와, Suchman(1987)의 상황적 행위 이론이 지닌 지나치게 미세한 분석 단위 문제를 동시에 우회하는 중간 지점으로 채택되었다. Wong-Villacres 등(2020)은 이 렌즈를 저소득 라틴계 이민자 부모 35명과 1개월 참여디자인(PD) 작업에 적용하여, "Consejos(훈육적 조언)"와 "Closeness with teachers(교사와의 친밀성 추구)"라는 두 전략을 역량·목표·구조적 제약의 관계로 해부했다.

1.2 연구의 출발점과 기여

이러한 해부는 풍부한 질적 통찰을 제공하지만, 본질적으로 서술적(descriptive) 형태에 머문다. 서로 다른 참여자·전략 간 비교, 혹은 특정 기술 개입 전후의 효과 변화는 여전히 정성적 판단에 의존할 수밖에 없다. 이 서술적 한계를 어떻게 넘어설 것인가라는 문제의식에서 본 연구가 출발했으며, 그 최초의 형태와 재정식화 과정은 3장에서 상세히 다룬다. 본 연구는 다음을 기여한다. 첫째, Swidler의 culture-in-action 개념(도구함·역량·전략·settled/unsettled 국면)을 조작적으로 정의된 열 개의 하위 명제(줄여서 FOL)로 분해하는 프레임워크를 제안한다. 둘째, 이 중 가장 취약한 고리인 결측 판별 항목을 반증 논리로 검토하여, 이분법적 판별이 과소추출 오류를 은폐한다는 방법론적 결함을 드러내고 3단계 신뢰도 분류로 개정한다. 셋째, 개정된 프레임워크를 앵커 논문이 실제로 보고한 원문 인용에 적용하여 실행 가능성을 예시적으로 입증하고, 완전한 실험적 검증이 요구하는 조건을 명시한다.

2. 관련 연구

2.1 실천이론과 문화사회학

Bourdieu(1977)는 사회가 가치 있다고 여기는 자본(capital)의 축적 메커니즘이 이미 자본을 가진 집단에 유리하게 작동한다고 보았다. 이 관점은 구조적 제약을 설명하는 데는

강력하지만, 소외된 집단이 권력에 저항하기 위해 동원하는 역량을 설명하는 데는 지나치게 결정론적이다. Suchman(1987)의 상황적 행위(situated action) 이론은 "특정한 장(setting)에서 행위하는 사람들의 일상 활동"에 초점을 맞추어 개인의 행위성(agency)을 복원하지만, 그 분석 단위가 지나치게 미세하여 장기간에 걸친 자료 분석에는 적합하지 않다. Swidler(1986)의 culture-in-action 이론은 이 두 접근 사이의 중간 지점을 제공한다. 구조적 제약을 부정하지 않으면서도, 개인이 문화적 도구함에서 창의적으로 역량을 구성해 전략적 행위를 조립하는 과정을 조명하기 때문이다.

2.2 자산기반 HCI 디자인

Kretzmann & McKnight(1996)의 자산기반 지역개발(ABCD)과 Moll 등(1992)의 Funds of Knowledge 개념은 결핍이 아닌 자산에서 개입을 시작해야 한다는 원칙을 확립했다. Cho 등(2019)은 이 원칙을 HCI에 적용하여, 히스패닉 가정의 정보 확산에 활용하는 comadrazgo(여성 간 긴밀한 우정)를 자산으로 식별하고 이를 레버리지하는 SMS 시스템을 설계했다. Wong-Villacres 등(2020)은 이러한 자산기반 HCI 연구의 계보 위에서, 자산을 어떻게 식별할 것인가를 넘어 situated한 자산을 설계에 어떻게 연결할 것인가라는 방법론적 공백을 culture-in-action 렌즈로 메운다.

2.3 AI 연구 에이전트와 정량적 환각

Lewis 등(2020)이 제안한 검색결합생성(Retrieval-Augmented Generation, RAG)은 파라메트릭 언어모델과 비파라메트릭 검색 인덱스를 결합해, 생성된 내용의 출처(provenance)를 제공할 수 있는 가능성을 열었다. Yao 등(2023)의 ReAct는 언어모델의 추론(reasoning)과 행동(acting, 예: 검색 도구 호출)을 교차시켜, 사고 사슬(chain-of-thought)만으로 발생하는 환각과 오류 전파를 줄이는 방법을 제시했다. 그러나 Ji 등(2023)의 연구가 정리하듯, 언어모델이 생성하는 텍스트에는 근거 없는 내용을 사실처럼 제시하는 환각이 구조적으로 내재해 있다. 이 세 흐름은 AI가 정보를 찾고, 근거를 추출하고, 검증할 수 있다는 기술적 가능성과, 그럼에도 근거 없는 값을 지어낼 수 있다는 위험을 동시에 시사하며, 본 연구가 다루는 핵심 긴장이다.

3. 연구의 출발점: 최초 가설과 그 재정식화

3.1 최초의 FOL-0과 열 개의 하위 명제

본 연구의 최초 FOL-0는 다음과 같은데, "AI 에이전트는 개인의 문화적 도구함·역량·전략처럼 본래 수치화하기 어려운 질적 현상을, 원문의 의미를 왜곡하지 않으면서 수치적 값으로 변환할 수 있다."는 것이다(여기서 FOL이란, 1차 논리(First-Order Logic)의 약자로 삼단논법처럼 참(True)/거짓(False)을 엄밀하게 판별할 수 있는 연역적 인과관계 문장을

의미한다.). 이 주장을 지탱하기 위해 처음 도출된 열 개의 FOL은 다음과 같다.

FOL 0-1: 보고서 속 이해관계자가 사용하는 도구함 요소(예: 전화망·중개인을 통한 연락·가족 대리 신청)의 다양성이나 밀도를 채널 수·언급빈도 같은 지표로 환산할 수 있는지를 물었다.

FOL 0-2: 특정 역량(예: 숙련자의 오랜 경험적 노하우)이 어떤 도구함 요소에서 비롯되었는지 그 연결의 강도를 인용 근접도와 같은 점수로 매길 수 있는지를 물었다.

FOL 0-3: 기존 운영이 안정적으로 서술된 문단에서 역량이 목표 선택에 미치는 영향력을 0에서 1 사이의 강도로 산정할 수 있는지를 물었다.

FOL 0-4: 위기 상황이 서술된 대목에서 이해관계자가 기존 전략을 재검토하는 정도를 계량화할 수 있는지를 물었다.

FOL 0-5: 하나의 전략을 구성 역량들로 분해해 각각의 기여 비중을 퍼센트로 배분할 수 있는지를 물었다.

FOL 0-6: (10개 중 가장 중요한 항목으로 설정) 보고서에 명시되지 않은 역량을 AI가 "값 없음(N/A)"으로 정직하게 처리하는지, 아니면 없는 수치를 임의로 지어내는지를 물었다.

FOL 0-7: 차량 정원이나 예산과 같은 구조적 제약(hard constraint)이 특정 역량의 발현을 얼마나 방해하는지를 가용률(%)과 같은 지표로 환산할 수 있는지를 물었다.

FOL 0-8: 동일한 역량이 맥락에 따라 자산이자 동시에 제약으로 작용할 때 이를 부호 있는 점수(-1에서 +1)로 구분해 표현할 수 있는지를 물었다.

FOL 0-9: 여러 역량과 제약을 종합했을 때 드러나는 상위 목표에 대한 부합도를 단일 점수로 산출할 수 있는지를 물었다.

FOL 0-10: 특정 기술 개입 전후로 역량-목표 적합성 점수가 어떻게 변화하는지 비교 가능한 수치로 제시할 수 있는지를 물었다.

이 열 가지 물음을 종합해 최초로 세운 검증 가설(FOL-0)은, 검색·근거 추출·검증 절차를 포함한 AI 연구 에이전트를 활용하면 일반 언어모델의 요약이나 단순 구조화 프롬프트보다 보고서 속 수치화 불가능한 질적 현상을 원문에 부합하는 수치로 변환하는 정확도가 높아지고, 근거 없이 수치를 지어내는 정량적 환각은 감소하리라는 것이었다.

3.2 재정식화의 필요성

그러나 최초의 FOL 0는 다음의 한계가 있었다. 첫째, 각 명제가 예시로 든 사례들이 실제로 존재하는 단일 원문을 지시하지 않아, "역추적 가능한 근거"라는 기준 자체를 검증할 방법이 없었다. 둘째, 이론적 배경이 명시되지 않아 도구함·역량·전략이라는 용어가 어

떤 학술적 개념에 대응하는지 불분명했다. 이에 본 연구는 실제로 존재하며 이 개념들을 정확히 정의해 사용하는 학술 논문을 앵커로 채택하는 절차를 밟았다. 곧 Swidler(1986)의 원 이론과 이를 HCI에 적용한 Wong-Villacres 등(2020)의 논문이다. 이하 4장과 5장은 열 가지 명제 각각이 이 앵커 위에서 어떻게 재정식화 되었는지를 서술한다.

4. 이론적 틀: Culture-in-Action의 재구성

Swidler(1986)의 이론은 세 가지 구성요소로 이루어진다. 도구함(toolkit)은 상징·이야기·의례로 구성된 문화적 자원의 총체이며, 역량(capacity)은 그 도구함으로부터 길러지는 습관·기술·스타일이고, 전략적 행위(strategies of action)는 역량을 동원해 조립한, 목표를 지속적으로 추구하는 방식이다. 이 이론은 또한 안정(settled)과 격변(unsettled) 국면을 구분한다. 안정된 국면에서는 이미 갖춘 역량과 전략의 가용성이 목표 선택 자체를 결정하는 반면, 격변의 국면에서는 개인이 자신의 도구함을 의식적으로 재검토하며 전략을 재구성한다. 흥미롭게도 Wong-Villacres 등(2020)은 이 구분을 실제 자료 분석에 그대로 적용하여, 부모들이 심각한 학업 문제에 직면했을 때 겪는 상태를 "unsettled times"라고 명명하며 서술했는데, 이 사실은 6장에서 볼 것처럼 이론적 구성개념이 실제 서술 안에 찾아낼 수 있는 형태로 존재한다는 것을 보여주는 첫 단서가 된다.

5. 방법론: 재정식화된 프레임워크

5.1 AI 에이전트가 갖추어야 할 세 기능

본 프레임워크가 요구하는 에이전트는 세 기능을 수행해야 한다. 원문에서 관련 대목을 정확히 찾아내는 검색(Search), 찾아낸 대목을 근거 문장으로 인용하며 값을 산출하는 근거추출(Grounding), 그리고 산출된 값이 실제로 근거 문장과 일치하는지 재확인하는 검증(Verification)이다.

5.2 열 개의 하위 명제 재정식화 - 주사슬과 보조사슬

3.1절에서 소개한 열 개의 원형 명제는 앵커 논문 위에서 다음과 같이 구체화되었다. FOL 0-1(도구함 다양성)은 도구함 요소를 개체로 식별·목록화하고, 고유 요소 수를 언급 참여자 수로 나눈 다양성 지수를 산출하는 것으로 정식화되었다. FOL 0-2(연결강도)는 문장 간 거리와 인과 연결어의 존재를 반영해 $1/(\text{문장거리}+1)$ 이라는 근접도 산식으로 다듬어졌다. FOL 0-3(안정 국면의 영향력)은 역량과 전략이 같은 문장에서 공기하는 정도와 확인 표현의 존재를 근거로 0에서 1 사이의 점수를 매기는 방식으로, FOL 0-4(격변 국면의 재검토 빈도)는 전략전환을 알리는 표현의 등장 빈도를 해당 문단의 전체 문장 수로 나누는 방식으로 각각 재정식화 되었다. FOL 0-5(전략의 역량 기여도 분해)는 원문에 명시적 가중치가 없는 경우 균등 배분임을 밝히는 조건을 달아 유지되었고, FOL 0-7(구조적

제약의 가용률)은 원문에 실제로 명시된 수치만을 사용해야 한다는 제약이 추가되었으며, FOL 0-8(역량의 양가성)은 긍정 문맥 수에서 부정 문맥 수를 뺀 값을 전체 문맥 수로 나누는 부호 점수로 정식화되었다. FOL 0-9(다중요인 종합 부합도)와 FOL 0-10(개입 전후 변화 추적)은 각각 가중치 가정을 투명하게 명시하는 것과, 개입 전후 문단에 동일한 산식을 일관되게 적용하는 것을 조건으로 유지되었다.

이 아홉 개 명제 가운데, FOL 0-2 · FOL 0-4 · FOL 0-7 · FOL 0-8은 5.1절의 세 기능을 직접 활용해 정확도와 환각 감소라는 목표를 곧바로 검증하는 주사슬을 이루고, FOL 0-1 · FOL 0-3 · FOL 0-5 · FOL 0-9 · FOL 0-10는 그 전제조건이 되거나 결과를 종합하는 보조사슬을 이룬다.

5.3 FOL 0-6의 재검토: 이분법에서 3단계 분류로

남은 하나, 가장 중요한 항목으로 지목되었던 FOL 0-6(결측 판별)은 단순한 재정식화를 넘어 근본적인 재검토를 거쳤다. 이 명제는 원래 "정보가 있다/없다"는 이분법을 전제로, AI가 정보 부재를 정직하게 N/A로 처리하는지를 물었다. 그러나 이 이분법은 실제 서술에서 명시적 진술과 완전한 부재 사이에 암묵적으로 추론 가능한 근거라는 중간 지대가 존재한다는 사실을 놓친다. 검증 절차가 근거 없는 값 생성, 즉 과잉추출만을 억제하도록 설계되면, 에이전트는 그 대가로 추론 가능한 정보까지 N/A로 처리하는 과소추출에 빠질 수 있다. 이 경우 환각이 없다는 지표만으로는 아무 답도 하지 않는 에이전트가 최고 점수를 받는 자기모순이 발생한다. 이에 이 명제는, AI 에이전트가 정보의 존재 여부를 이분법이 아니라 명시적 근거·암묵적 근거(신뢰도 점수 부여)·부재라는 3단계로 판별해야 하며, 성공 기준 또한 과잉추출뿐 아니라 과소추출까지 함께 낮추는 것이어야 한다는 형태로 개정되었다.

5.4 최초 가설의 재정식화

이러한 재검토를 반영해, 3.1절 말미에 제시했던 최초의 검증 가설 또한 다듬어졌다. 재정식화된 가설은, 검색·근거추출·검증 절차를 갖춘 AI 연구 에이전트가 단순 언어모델 요약 대비 근거 없는 수치 생성을 줄이는 동시에 원문에 암묵적으로 내포된 정보를 놓치지 않고 포착하여 두 오류를 동시에 낮추는 방향으로 원문-부합 정확도를 개선하리라는 것이다. 다만 환각 감소가 단순히 응답 회피, 곧 N/A의 남발로 달성된 것이라면 이는 이 가설의 반증 사례로 간주되어야 한다는 단서가 함께 명시되었다.

6. 사례 적용: 앵커 논문 데이터 재분석

본 절은 5장에서 재정식화된 프레임워크를 앵커 논문이 실제로 보고한 원문 인용에 근거 추적이 가능한 형태로 적용한다. 모든 수치는 수기 산출(manual computation)이며, 계산에 사용한 가중치가 원문에 명시되지 않은 경우 이를 매번 밝힌다.

6.1 "Consejos" 전략 분석

도구함 다양성을 묻는 FOL 0-1를 적용하면, 부모들이 동원한 도구함 요소는 최소 네 가지로 식별된다. 가족 출신과 계급에 관한 서사("I tried to make them see where they come from...", Claudia), superación(자기 성취) 담론("he needs to have a clearly defined goal...", Reyna), 개인적 실패-극복 서사("the best students... calling me a 'burro'...", Ruben), 그리고 인내에 관한 신념("my strength is to be perseverant...", Reyna)이다. 다양성 지수, 즉 고유 요소 수를 언급 참여자 수로 나눈 값은 $4/3$, 약 1.33이 된다. 연결강도를 묻는 FOL 0-2를 적용하면, Ruben의 역량("academic resources can be mixed with values-based ones")은 그의 개인 서사와 동일 문단.인접 문장에서 직접 서술되어 문장거리가 0이 되고, 따라서 연결강도는 1.0에 이른다. 안정 국면의 영향력을 묻는 FOL 0-3은, "As most of our participants, Reyna only used values-based resources... to craft consejos for motivating academic development"라는 확인적 서술을 근거로 0.9라는 점수를 산출한다.

6.2 "Closeness with teachers" 전략 분석

격변 국면의 재검토 빈도를 묻는 FOL 0-4에서 가장 강력한 사례가 발견된다. 원문은 4장에서 언급한 Swidler의 unsettled 개념을 그대로 인용하여, "parents face what a culture-in-action theory calls unsettled times... they try out different strategies to address the problem"라고 서술한다. "Looking back, those were hard days. I had no idea what to do, and prayed to God for an answer"라고 회고한 Lupita가 이어서 "looked into her cultural toolkit and found a strategy she felt could work"라고 묘사되는 대목을 포함하는 문단에서, 전략전환을 알리는 표현은 전체 문장 약 열두 개 중 세 번 등장하여 재검토 지수는 0.25가 된다.

전략의 역량 기여도 분해를 묻는 FOL 0-5는, Closeness 전략을 인내와 용기, 권위자에 대한 신뢰 추구, 협상 능력이라는 세 개 역량으로 분해하되, 원문에 상대적 가중치가 없으므로 각각 33.3%씩 균등 배분한다는 조건을 명시한다. 결측 판별을 묻는 FOL 0-6은 여기서 3단계 분류의 실제 효과를 보여준다. "all our participants, at a certain point, had tried to get closer to teachers"는 명시적 근거이므로 100%로 판정되지만, 개별 참여자의 평균 접촉 횟수는 원문에 없으므로 N/A로 남는다. 한편 Margarita가 다른 학습자원을 거부한 심리적 강도는("I first have to do what the teacher told me to do"라는 태도만 서술되어 있을 뿐 명시적 수치는 없으므로)신뢰도 0.6의 암묵적 근거로 분류된다. 바로 이 세 번째 판정이 5.3절에서 개정한 3단계 분류가 실제로 작동하는 지점이다.

구조적 제약의 가용률을 묻는 FOL 0-7은, 원문에 실제로 명시된 수치인 "teachers do not have the time to meet with 20 parents wanting to talk to them per day"와 정보 신뢰도 평점 "2.5/5"를 그대로 사용한다. 역량의 양가성을 묻는 FOL 0-8은, "perseverance

helped many parents pursue a form of support for children, but it also blinded them from other opportunities"라는 한 문장 내 병렬 서술을 근거로 삼아, 긍정 문맥 하나와 부정 문맥 하나가 상쇄되어 부호 점수 0이라는, 완전히 균형 잡힌 양가성을 드러낸다.

6.3 종합 및 개입 전후 비교

다중요인 종합 부합도를 묻는 FOL 0-9는, 원문이 직접 제시한 종합 사례(**"Juxtaposing both reveals that their overall goal is safe self-empowerment"**)를 이용해, 역량 세 개에서 제약 두 개에 절반의 가중치를 부여해 상쇄한 값을 전체 요소 수로 나누어 0.4라는 부합도를 얻는다. 이때 제약에 절반의 가중치를 부여한다는 가정은 원문에 없는 임의의 가정임을 밝혀둔다. 개입 전후 변화를 묻는 FOL 0-10은, 개입 전 현행 closeness 전략(시간 부족과 낮은 신뢰로 제약된 상태)의 부합도 0.25와, 원논문이 제안한 개입(**"intelligent agents embedded in existing parent-teacher communication channels"**) 이후 제약이 하나로 줄어든 상태의 부합도 0.5를 비교하여, +0.25라는 변화량을 산출한다.

7. 논의

6장의 적용 결과는 주사슬을 이루는 네 개의 FOL, 곧 연결강도·재검토 빈도·결측 판별·가용률·양가성 항목이 모두 원문 근거로 역추적 가능한 수치를 산출할 수 있음을 보여준다. 특히 6.2절에서 확인했듯 앵커 논문 저자들이 Swidler의 unsettled 개념을 문자 그대로 차용해 서술했다는 사실은, 이론적으로 정의된 구성개념이 실제 질적 서술 안에 찾아낼 수 있는 형태로 이미 존재함을 시사한다. 이는 최초의 FOL 0가 주장했던 바(질적 현상이 원문의 의미를 왜곡하지 않고 수치로 옮겨질 수 있다는 것)을 지지하는 가장 직접적인 증거다. 동시에 FOL 0-5 · FOL 0-9 · FOL 0-10에서 반복된 균등가정 표기는, 원문이 가중치나 빈도를 항상 명시하지는 않는다는 한계도 함께 보여준다. 즉 이 프레임워크의 신뢰도는 결국 원문에 없는 값에 대한 정직한 표기, 곧 재정식화된 여섯 번째 명제에 좌우된다.

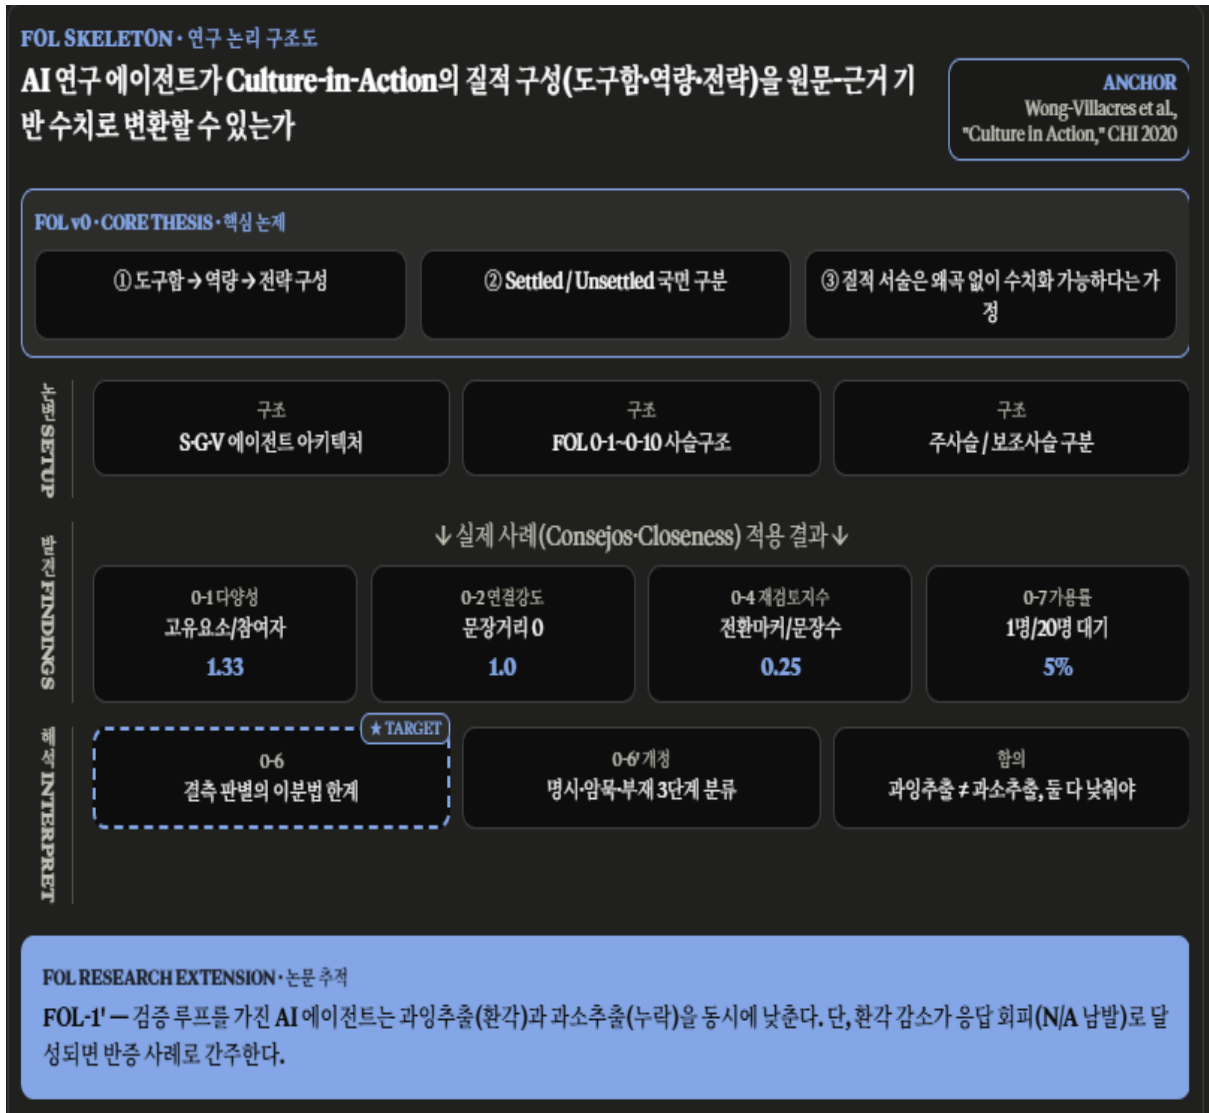
8. 한계 및 향후 연구

본 연구의 사례 적용은 한 명의 분석자가 수기로 원문을 대조하며 산출한 것이며, 검증 루프가 있는 에이전트와 없는 에이전트를 실제로 병렬 가동해 과잉 추출률과 과소 추출률을 통계적으로 비교하는 실험은 수행되지 않았다. 따라서 재정식화된 최종 가설이 주장하는 두 오류의 동시 저감은 방법론적 실행 가능성만 예시적으로 입증되었을 뿐, 완전히 검증되지는 않았다. 향후 연구는 검증 루프의 유무를 조작한 에이전트 간 비교 실험, 다수의 인간 코더를 이용한 암묵적 근거 신뢰도의 평가자 간 신뢰도 측정, 그리고 Consejos와 Closeness 외 다른 전략 사례로의 일반화 가능성 검토를 과제로 삼는다.

9. 결론

본 연구는 도메인 일반적인 형태로 세워졌던 최초의 가설(AI 에이전트가 문화적 도구 함·역량·전략을 원문 왜곡 없이 수치화할 수 있다는 주장과 이를 지탱하는 열 개의 FOL)이 실제 앵커 논문을 만나며 어떻게 구체화되었는지를 보였다. Swidler(1986)의 culture-in-action 이론과 이를 HCI에 적용한 Wong-Villacres 등(2020)의 논문 사이에서, 이 질적 렌즈의 산출물이 AI 에이전트에 의해 원문-근거 기반으로 수치화될 수 있는가라는 연구 공백을 확인했고, 가장 취약했던 결측 판별 항목을 반증을 통해 3단계 신뢰도 분류로 개정했다. 앵커 논문의 실제 사례에 대한 예시적 적용은 이 프레임워크의 실행 가능성을 뒷받침하며, 과잉추출과 과소추출을 동시에 낮추는 것이 진짜 성공 기준이라는 재정식화된 가설을 제시한다. 이 가설의 완전한 실험적 검증은 향후 과제로 남는다.





참고문헌

- Bourdieu, P. (1977). *Outline of a Theory of Practice*. Cambridge University Press.
- Cho, A., Herrera, R. G., Chaidez, L., & Uriostegui, A. (2019). The Comadre Project: An Asset-Based Design Approach to Connecting Low-Income Latinx Families to Out-of-School Learning Opportunities. In *Proceedings of the 2019 CHI Conference on Human Factors in Computing Systems*. ACM.
- Ji, Z., Lee, N., Frieske, R., Yu, T., Su, D., Xu, Y., ... & Fung, P. (2023). Survey of Hallucination in Natural Language Generation. *ACM Computing Surveys*, 55(12), Article 248. <https://doi.org/10.1145/3571730>
- Kretzmann, J., & McKnight, J. P. (1996). Assets-based community development. *National Civic Review*, 85(4), 23–29.

- Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., ... & Kiela, D. (2020). Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. In *Advances in Neural Information Processing Systems 33 (NeurIPS 2020)*.
- Moll, L. C., Amanti, C., Neff, D., & Gonzalez, N. (1992). Funds of knowledge for teaching: Using a qualitative approach to connect homes and classrooms. *Theory into Practice*, 31(2), 132–141.
- Suchman, L. A. (1987). *Plans and Situated Actions: The Problem of Human-Machine Communication*. Cambridge University Press.
- Swidler, A. (1986). Culture in action: Symbols and strategies. *American Sociological Review*, 51(2), 273–286.
- Wong-Villacres, M., DiSalvo, C., Kumar, N., & DiSalvo, B. (2020). Culture in Action: Unpacking Capacities to Inform Assets-Based Design. In *Proceedings of the 2020 CHI Conference on Human Factors in Computing Systems (CHI '20)*. <https://doi.org/10.1145/3313831.3376329>
- Yao, S., Zhao, J., Yu, D., Du, N., Shafran, I., Narasimhan, K., & Cao, Y. (2023). ReAct: Synergizing Reasoning and Acting in Language Models. In *Proceedings of the 11th International Conference on Learning Representations (ICLR 2023)*.